

华中科技大学

高级机器学习理论 课程报告

面向工业设备预测性维护的物理机理
增强成本敏感故障预测方法研究

学 生 姓 名： 姓名

专 业 班 级： 专业

任 课 教 师： 指导教师 教授

提 交 日 期： 2026 年 05 月 31 日

高级机器学习理论课程报告

目 录

1	引言	(1)
2	数据集与问题定义	(3)
3	方法与算法设计	(5)
3.1	基础模型与扩展模型	(5)
3.2	物理机理增强特征工程	(5)
3.3	成本敏感阈值优化	(6)
3.4	OOF Stacking 与异常检测辅助特征	(7)
4	实验设计	(8)
4.1	数据预处理	(8)
4.2	评价指标	(8)
4.3	实验组设置	(8)
5	实验结果与分析	(10)
5.1	成本敏感结果	(10)
5.2	统计指标最优结果	(12)
5.3	消融实验	(14)
6	可解释性分析	(16)
7	软件结构与实现方法	(18)
8	总结与展望	(19)
	参考文献	(21)

1 引言

随着智能制造和工业 4.0 的发展，制造系统中大量设备能够持续产生温度、转速、扭矩、磨损等运行数据。对一条真实产线而言，设备故障并不是一个抽象的二分类标签，而往往意味着节拍被打断、排产被重排、维修人员临时介入，甚至一批在制品需要重新质检。传统维护方式通常包括事后维修和定期维修。事后维修会在设备已经发生故障后才进行处理，代价最高；定期维修虽然能降低故障风险，但也可能把仍可工作的部件提前换掉，形成过度维护。预测性维护的价值正在于把维护决策从“坏了再修”推进到“将坏未坏时介入”，用数据提前捕捉设备状态的细微变化。

本报告把这一问题理解为一个带有工业约束的风险排序问题，而不仅是一个普通分类任务。模型输出的概率并不直接等于最终决策，真正要回答的问题是：当设备表现出某种温度、转速、扭矩和磨损组合时，它是否已经进入值得停机检查的风险区间？这个问题天然带有成本权衡。若模型把正常设备判成故障，最多带来一次额外检查；若模型漏掉故障，则可能带来停机、损坏和安全风险。因此，一个面向维护场景的算法应当愿意牺牲一部分精确率，换取更低的漏报率和更可控的总成本。

工业故障预测存在两个突出难点。第一，故障样本数量远少于正常样本，数据高度不平衡。第二，误报和漏报的代价并不对称。误报通常只会造成额外检查，而漏报可能导致设备损坏、生产中断甚至安全风险。因此，预测性维护模型不能只追求整体准确率，而应重点关注故障召回率、少数类识别能力和实际维护成本。在本实验中，如果模型永远预测“正常”，仍然可以获得很高的 Accuracy，但这样的模型对维护人员没有任何帮助。它像一个永远乐观的值班员，在报表上看起来稳定，却在真正的故障来临时保持沉默。

本文的主要工作包括：使用多个基础算法和扩展算法建立完整对比实验；引入 MCC、Balanced Accuracy、PR-AUC 和经济成本矩阵，避免 Accuracy 指标误导；根据工业设备失效机理构造温差、功率代理、磨损-扭矩交互等物理增强特征；设计成本敏感阈值优化方法；构建 OOF Stacking 模型；引入 IsolationForest 异常检测辅助特征；使用特征重要性和 SHAP 方法解释模型预测结果。为保证实验可复现，本文将代码、数据、结果表格、图像和报告 PDF 整理为公开项目，发布于 GitHub: <https://github.com/UniversalCAI/predictive-maintenance-failure-prediction>。整体思路不是简单

高级机器学习理论课程报告

地堆叠模型，而是沿着“先识别评价陷阱，再加入机理信息，最后把预测概率转化为维护决策”的路线展开。

2 数据集与问题定义

本文使用 AI4I 2020 Predictive Maintenance Dataset^[1]。该数据集包含 10000 条样本，描述工业设备在不同运行状态下的传感器读数及故障情况。主任务标签为 **Machine failure**，其中 1 表示设备发生故障，0 表示设备正常。数据中故障样本占比为 3.39%，说明该任务具有明显类别不平衡性。实验采用训练集、验证集、测试集划分，样本量分别为 6000、2000、2000，并保持故障比例分层一致。

从变量构成看，该数据集很适合用来讨论“数据驱动”和“物理直觉”的结合。空气温度和过程温度刻画设备热状态，转速和扭矩共同反映机械负载，工具磨损时间则是长期运行累积效应的简化表示。如果只把这些变量当作普通表格列，模型仍然可以学习到一些统计相关性；但从工业维护角度看，更有意义的问题是这些变量如何共同形成失效条件。例如，单独的高转速未必危险，单独的高扭矩也未必危险，但低速高扭矩、高磨损高温、温差异常扩大等组合状态往往更接近工程师理解中的风险信号。

表 2.1: 主要输入特征

特征	含义
Type	产品类型
Air temperature [K]	空气温度
Process temperature [K]	过程温度
Rotational speed [rpm]	主轴转速
Torque [Nm]	扭矩
Tool wear [min]	工具磨损时间

数据集中还包含 TWF、HDF、PWF、OSF、RNF 五个故障类型字段，分别代表工具磨损故障、散热故障、电力故障、过载故障和随机故障。这些字段属于标签信息，不能作为二分类模型的输入特征，否则会造成数据泄漏。本文仅将这些字段用于故障类型统计和错误分析。这个处理非常关键：如果把故障类型字段放进输入，模型可以“提前看到答案”，指标会异常漂亮，却失去实际部署意义。本文把这条边界作

高级机器学习理论课程报告

为实验设计的基本约束，保证所有性能提升都来自原始传感器变量、机理特征和学习算法本身。




图 2.1: 类别分布




图 2.2: 故障类型分布

从类别分布可以看到，本任务中的正样本并不是均匀、充足地覆盖所有故障状态。散热、电力、过载、工具磨损等故障在样本中出现频率不同，随机故障更难由有限的连续传感器变量解释。这意味着模型不可能只依靠一种简单边界完成任务：它既需要捕捉少数类样本，又需要在不同故障机理之间找到共通的风险结构。后文的实验结果也表明，物理特征、类别权重和阈值优化分别从不同角度补足了这个困难。

3 方法与算法设计

3.1 基础模型与扩展模型

本文首先使用基础算法建立可解释的对照组，并引入近年代表性集成学习模型作为扩展算法。基础模型包括 Logistic Regression、KNN、Linear SVM 和 Decision Tree；扩展模型包括 Random Forest、XGBoost^[2]和 LightGBM^[3]；创新模型包括物理机理增强模型、OOF Stacking^[4]和异常检测辅助特征模型。

模型组的安排遵循由浅入深的逻辑。Logistic Regression 和 Linear SVM 提供近似线性边界，可用于观察原始特征是否已经包含足够清晰的故障分离信息；KNN 体现局部相似性假设，适合检验故障样本是否在特征空间中自然成簇；Decision Tree、Random Forest、XGBoost 和 LightGBM 能够表达非线性关系和变量交互，更符合工业设备状态由多因素共同决定的特点。最后，Stacking 和异常检测特征并不是为了单纯追求复杂度，而是尝试回答一个更实际的问题：不同模型看到的风险是否互补，正常样本训练出的“异常感”能否帮助识别故障边缘样本。

3.2 物理机理增强特征工程

AI4I 数据集中的故障并非完全随机产生，而是与温度、转速、扭矩、磨损等物理变量存在明确关系。过载故障往往与高扭矩和低转速有关，电力故障与转速和扭矩共同决定的功率负载有关，工具磨损故障与磨损时间和加工负载有关。若仅将原始传感器变量输入模型，模型需要自行学习这些乘积、比值和差值关系。对于样本充足的大数据任务，这种关系也许可以完全交给模型；但在故障样本只有 3.39% 的情况下，少数类信息非常珍贵。把部分工程知识显式写成特征，相当于提前告诉模型哪些变量组合值得关注，从而减少模型在小样本故障区域里的搜索难度。为增强模型对工业失效机理的表达能力，本文构造了物理机理增强特征，如表 3.1 所示。

高级机器学习理论课程报告

表 3.1: 物理机理增强特征

增强特征	构造方式	物理含义
temp_delta	过程温度 - 空气温度	散热条件和热交换状态
power_proxy	转速 × 扭矩	设备功率负载代理量
torque_per_speed	扭矩 / 转速	低速高扭矩异常负载
speed_torque_ratio	转速 / 扭矩	转速与负载匹配关系
wear_torque	工具磨损 × 扭矩	磨损与机械负载耦合
wear_process_temp	工具磨损 × 过程温度	磨损与热状态耦合
thermal_speed_load	温差 × 转速	热状态与转速共同影响

这些特征均由原始传感器变量确定性计算得到，不使用故障类型标签，因此不会造成数据泄漏。该模块是本文最核心的创新之一。其背后的思想可以概括为：不要让模型从零开始猜测工业机理，而是把“低速高扭矩”“高磨损高温”“高负载功率”这类工程师会自然关注的状态翻译成机器学习模型更容易利用的数值特征。

3.3 成本敏感阈值优化

普通二分类模型通常使用 0.5 作为分类阈值。然而在预测性维护中，漏报故障的代价远高于误报。一个输出 0.3 故障概率的样本，在普通分类任务中可能会被判为正常；但对维护人员而言，这个概率已经足以触发复查。本文构建维护成本矩阵，FP（误报）成本为 10，FN（漏报）成本为 500。总成本定义为：

$$\text{Total Cost} = 10 \times \text{FP} + 500 \times \text{FN}. \quad (3.1)$$

本文在验证集上对阈值从 0.01 到 0.99 进行网格搜索，分别寻找成本最优、F1 最优和 MCC 最优阈值。阈值搜索的意义在于把模型概率转化为维护策略：较高阈值更保守，误报少但可能漏掉故障；较低阈值更敏感，会增加检查次数，却能把更多故障提前捞出来。因此，阈值不是一个固定数学常数，而是业务风险偏好的体现。

3.4 OOF Stacking 与异常检测辅助特征

OOF Stacking 使用 Stratified K-Fold 生成折外预测概率，再由元学习器学习不同模型之间的互补关系。该方法避免了直接使用训练集拟合预测训练元学习器造成的数据泄漏。直观来看，Stacking 像是让多个“值班员”分别给出风险判断，再由一个更轻量的元模型学习何时相信谁。本文还仅使用正常训练样本训练 IsolationForest，为所有样本生成异常分数，作为额外输入特征加入模型。这样做的动机是：故障样本很少，但正常运行状态相对充分，若某个样本明显偏离正常工况，即使它不完全符合已见过的故障模式，也应当被模型额外关注。

4 实验设计

4.1 数据预处理

实验中删除 UDI、Product ID 等无预测意义字段，并删除故障类型标签字段以避免数据泄漏。对类别变量 Type 使用 One-Hot Encoding。对 Logistic Regression、KNN、Linear SVM 等模型使用标准化，对树模型保留原始数值尺度。在创新实验中，进一步加入由原始传感器变量计算得到的物理机理增强特征。

预处理阶段的目标不是把所有变量机械地送入模型，而是尽量模拟真实部署时能够获得的信息。UDI 和 Product ID 更接近样本索引或产品编号，本身不表达设备状态；故障类型字段虽然与目标高度相关，但只有故障发生或标注完成后才知道，不能作为上线预测输入。相比之下，温度、转速、扭矩和磨损时间是设备运行时可以实时读取的变量，围绕这些变量构造特征，才符合预测性维护“提前判断”的要求。

4.2 评价指标

由于数据高度不平衡，本文不以 Accuracy 作为唯一评价指标。主要指标包括：Accuracy、Precision、Recall、F1-score、ROC-AUC、PR-AUC、MCC^[5]、Balanced Accuracy 和仿真维护成本。其中 Recall、PR-AUC、MCC、Balanced Accuracy 和维护成本是重点指标，因为它们更适合类别不平衡的工业故障预测任务。Accuracy 回答的是“总体上有多少样本判对”，而维护场景更关心“故障有没有被提前发现”。PR-AUC 比 ROC-AUC 更能反映少数类排序质量，MCC 在正负样本极不平衡时比 F1 更稳定，Balanced Accuracy 则避免多数类样本支配评价结果。成本指标进一步把统计错误翻译成维护代价，使算法比较更接近实际决策。

4.3 实验组设置

本文设置以下实验组：Dummy_All_Normal（揭示 Accuracy 的误导性）、基础模型组、集成模型组、类别权重模型、物理机理增强模型、非对称损失 XGBoost、OOF Stacking、OOF Stacking+ 异常特征以及物理特征 + 异常特征的组合模型。实验组之间不是简单横向罗列，而是逐步加入约束：先看普通模型会犯什么错，再看类别权重能否减少漏报，然后加入成本阈值，最后检验物理特征、集成学习和异常检测是

高级机器学习理论课程报告

否真正带来额外收益。

5 实验结果与分析

5.1 成本敏感结果

成本优化后，各模型显著提高故障召回率并降低漏报成本。加入物理机理增强特征后，成本最优模型为 XGBoost_Weighted_Physics，阈值为 0.19。其测试集结果如表 5.1 所示。

这个结果可以从维护现场的角度理解。阈值 0.19 看起来明显低于默认 0.5，但它并不是“放松要求”，而是把模型调整成更愿意发出预警的状态。对于故障占比极低的数据，许多真正故障样本的预测概率未必能超过 0.5；如果坚持默认阈值，模型会显得很谨慎，却把一部分关键故障留在正常类里。成本敏感阈值相当于告诉模型：宁可多安排一些检查，也不要让高风险设备继续运行到失效。

表 5.1: 成本最优模型在测试集上的结果

指标	数值
Accuracy	0.909
Precision	0.266
Recall	0.956
F1	0.417
Balanced Accuracy	0.932
MCC	0.478
ROC-AUC	0.978
PR-AUC	0.837
混淆矩阵	TN=1753, FP=179, FN=3, TP=65
仿真维护成本	3290

该模型只漏报 3 个故障样本，适合尽可能避免故障漏报的维护策略。与默认阈值下的 XGBoost 相比，总成本由 13060 降低至 3290，下降约 74.8%。与全预测正常的退化分类器相比，成本由 34000 降低至 3290，下降约 90.3%。从混淆矩阵看，模型

高级机器学习理论课程报告

用 179 次误报换来了 65 个故障检出和仅 3 个漏报。若把一次误报理解为额外检查，把一次漏报理解为潜在停机事故，这种交换在高安全要求的维护场景中是可以接受的。

当然，该模型 Precision 只有 0.266，意味着预警样本中有相当一部分最终并未发生故障。这并不说明模型无效，而是反映了成本敏感策略的取向：它把召回故障放在第一位。若企业的维修资源紧张，可能更偏向后文的 LightGBM_Physics 平衡方案；若设备停机损失巨大，则 XGBoost_Weighted_Physics 更符合“先保守排险”的策略。




图 5.1: 成本最优模型混淆矩阵




图 5.2: 成本最优模型阈值搜索曲线




图 5.3: 不同模型成本对比

5.2 统计指标最优结果

如果评价目标不是维护成本，而是更重视 Precision 与 Recall 的平衡，则物理机理增强后的 LightGBM 表现最优。F1/MCC 最优阈值下，LightGBM_Physics 在测试集上取得 Accuracy=0.992、Precision=0.919、Recall=0.838、F1=0.877、MCC=0.874、PR-AUC=0.893。

高级机器学习理论课程报告

与未加入物理特征的 LightGBM 相比，F1 从 0.752 提升至 0.877，MCC 从 0.747 提升至 0.874，PR-AUC 从 0.800 提升至 0.893。该结果说明物理机理增强特征显著改善了各项统计指标。

这一组结果提供了另一种维护策略。LightGBM_Physics 不像成本最优模型那样激进，它更强调预警的可信度。Precision 达到 0.919，说明一旦模型发出故障预警，大多数情况下确实对应故障样本；Recall 为 0.838，说明仍会漏掉一部分故障，但误报压力明显更小。换言之，XGBoost_Weighted_Physics 更像安全优先的“早报警”系统，LightGBM_Physics 更像维修资源受限时的“高置信报警”系统。两者并不是谁绝对替代谁，而是对应不同的业务成本偏好。




图 5.4: 不同模型 MCC 对比




图 5.5: ROC 曲线




图 5.6: PR 曲线

5.3 消融实验

本文对主要改进模块进行了消融实验，结果如表 5.2所示。

高级机器学习理论课程报告

表 5.2: 消融实验结果对比

实验	模型	阈值	Recall	Cost
A0	XGBoost 默认阈值	0.50	0.618	13060
A1	XGBoost 类别权重	0.50	0.868	5700
A2	XGBoost 类别权重 + 成本阈值	0.31	0.926	4530
A3	XGBoost 非对称损失	0.20	0.926	4440
A4	OOF Stacking	0.24	0.941	4230
A5	OOF Stacking+ 异常特征	0.21	0.956	3850
A6	XGBoost 权重 + 物理特征	0.19	0.956	3290
A7	OOF Stacking+ 物理特征	0.30	0.926	3880
A8	OOF Stacking+ 物理 + 异常	0.35	0.912	4270

消融结果显示，类别权重显著降低漏报成本，阈值优化进一步减少漏报。自定义非对称损失相比加权 XGBoost 略有成本优势。加入物理机理增强特征后，XGBoost_Weighted_Physics 的成本进一步降至 3290，MCC 达到 0.478，说明通过温差、功率代理、转速-扭矩比、磨损-负载交互等机理特征显式建模工业失效机制，是本实验中最有效的创新模块。

消融实验还说明，复杂模型并不总是线性叠加地带来收益。OOF Stacking 和异常检测特征能够降低成本，但当物理特征已经把关键失效机理表达出来后，再叠加异常特征并不一定继续提升，甚至可能引入一些噪声。这一点很有启发：在小样本故障预测中，最有价值的改进往往不是把模型做得越来越复杂，而是把任务中真正重要的结构信息表达清楚。

进一步观察漏报样本，成本最优模型仅漏报 3 个故障，其中 2 个属于工具磨损故障，还有 1 个没有明确故障类型标记。这些样本的预测分数均低于 0.03，说明它们在原始传感器空间中并没有呈现出模型已学习到的典型高风险形态。这个现象提示，若要继续减少最后几个漏报，仅靠当前低频表格变量可能不够，还需要引入振动、电流、声学等更敏感的早期状态信号。

6 可解释性分析

以物理机理增强后的树模型为解释对象，特征重要性结果显示，最重要的特征包括 speed_torque_ratio、torque_per_speed、wear_process_temp、Tool wear、Rotational speed、thermal_speed_load、power_proxy 和 Torque。




图 6.1: 特征重要性

speed_torque_ratio 与 torque_per_speed 反映转速和扭矩之间的匹配关系，可刻画低速高负载状态；power_proxy 反映设备功率负载；wear_process_temp 和 wear_torque 反映磨损与热状态、机械负载之间的交互。这些增强特征的重要性超过了部分原始特征，说明模型确实利用了本文提出的物理机理增强信息。

这个结果也解释了为什么物理特征能够带来性能提升。原始变量中的转速、扭矩、温度、磨损分别描述设备状态的不同侧面，但故障往往不是某一个变量单独越界，而是多个变量组合后进入危险区。模型把 speed_torque_ratio、torque_per_speed、wear_process_temp 等特征排在前列，说明它并不是机械记忆某个单点阈值，而是在学习“负载是否与转速匹配”“磨损是否叠加高温”“功率负载是否异常”这些更接近工程判断的问题。




图 6.2: SHAP 分析

SHAP 分析^[6]表明，转速-扭矩交互、磨损-温度交互、功率代理和工具磨损对故障概率的影响最明显。高扭矩与异常转速通常意味着设备承受更高机械负载，工具磨损增加则意味着设备长期工作导致失效风险上升，温度相关特征则反映设备热状态和散热条件。这与预测性维护中的物理机理一致。

可解释性分析的意义不只是给模型“事后找理由”。在工业场景中，维护人员通常不会只接受一个孤立的故障概率，他们更希望知道模型为什么预警。如果模型提示某台设备风险升高，同时解释结果显示风险主要来自低速高扭矩和磨损温度交互，那么维护人员可以优先检查传动、负载和刀具状态；如果风险主要来自温差异常，则可以优先检查散热条件。这样，模型输出就从一个黑箱分数变成了可执行的排查线索。

7 软件结构与实现方法

本文实验代码已发布在公开项目中，项目地址为<https://github.com/UniversalCAI/predictive-maintenance-failure-prediction>。核心入口为仓库路径 `src/run_all.py`，运行命令为 `python src/run_all.py`。程序能够自动完成数据读取、预处理、模型训练、物理机理增强特征构造、非对称损失 XGBoost、OOF Stacking、异常检测辅助特征、阈值搜索、图表保存和最佳模型保存。

公开仓库的组织方式与本文实验流程对应：`extttdata/raw/ai4i2020.csv` 保存原始 AI4I 数据；`extttsrc/run_all.py` 实现完整实验；`extttoutputs/tables/` 保存模型指标、阈值搜索、消融实验和错误分析结果；`extttoutputs/figures/` 保存类别分布、ROC/PR 曲线、成本对比、混淆矩阵、特征重要性和 SHAP 图；`extttreport/course_report.pdf` 保存本文报告 PDF；`extttREADME.md` 和 `extttDATASET.md` 分别说明运行方法、主要结果和数据集使用边界。

实现上，实验流程被拆分为数据处理、特征构造、模型训练、阈值评估、结果汇总和可解释性分析几个环节。这样做的好处是每个模块都可以单独复用。例如，当成本矩阵从 $FP=10$ 、 $FN=500$ 调整为其他业务假设时，不需要重新设计全部模型，只需要重新运行阈值搜索和成本评估；当新增传感器变量时，也可以在特征构造模块中扩展新的物理特征，再接入同一套训练和评价流程。对于课程报告而言，这种结构保证了实验可复现；对于真实项目而言，它也更接近可迭代的维护建模流程。

8 总结与展望

本文研究了工业设备预测性维护中的故障预测问题。实验表明，在故障样本比例仅为 3.39% 的高度不平衡数据中，准确率并不能真实反映模型价值。针对这一问题，本文提出物理机理增强的成本敏感故障预测方法，并结合类别权重、阈值优化、非对称损失、堆叠集成和异常检测辅助特征进行系统实验。

从整个实验过程看，最重要的收获并不是找到某一个单独最强的模型，而是建立了一条更贴近工业问题的建模路径。首先，用 Dummy 模型和多指标评价揭示 Accuracy 的误导性；其次，用类别权重和成本阈值把模型目标从“总体判对”转向“少漏故障”；然后，用物理机理增强特征把温度、转速、扭矩、磨损之间的工程关系显式表达出来；最后，通过 SHAP 和特征重要性把模型判断重新解释回工业语言。这样的流程比单纯比较算法排行榜更有意义。

实验结果显示，物理机理增强特征是最有效的创新模块。LightGBM_Physics 在统计指标上取得 $F1=0.877$ 、 $MCC=0.874$ 、 $PR-AUC=0.893$ ；XGBoost_Weighted_Physics 在成本敏感场景中取得最低仿真维护成本 3290，Recall 达到 0.956，仅漏报 3 个故障样本。

本文的主要结论如下：在预测性维护任务中，应避免单独使用 Accuracy 评价模型；MCC、Balanced Accuracy、PR-AUC 和经济成本矩阵更适合不平衡工业故障预测；物理机理增强特征是本实验中最显著的性能提升来源；阈值优化是降低漏报成本的关键步骤；SHAP 分析能够将模型结论映射到扭矩、磨损、转速和温度等工业机理。本文全部代码、数据、图表和报告文件已在公开 GitHub 仓库中整理，便于复现实验结果并进一步扩展。

在成本敏感目标下，XGBoost_Weighted_Physics 以 0.19 阈值取得最低维护成本 3290，Recall 达到 0.956，仅漏报 3 个故障样本，适合安全优先、停机代价高的场景。在统计平衡目标下，LightGBM_Physics 取得 $F1=0.877$ 、 $MCC=0.874$ 、 $PR-AUC=0.893$ ，适合维修资源相对有限、要求预警更可靠的场景。两类结果共同说明，预测性维护并不存在唯一固定的“最佳模型”，模型选择应当随业务成本、维护能力和风险偏好变化。

如果将本文方法进一步落到实际产线，可以采用分层预警方式：高风险样本进

高级机器学习理论课程报告

入立即检修队列，中等风险样本进入短周期复查队列，低风险样本继续保留在常规监测中。这样既保留成本敏感模型的高召回优势，又避免所有预警都转化为同等强度的维修动作。模型也不应被看作一次训练后长期不变的系统，而应随设备老化、工况变化和维修记录持续更新。特别是当某些误报样本在后续运行中逐渐出现真实异常时，它们本身也会成为有价值的早期预警样本。

未来工作可以进一步引入多任务学习，将是否故障与具体故障类型联合建模；也可以引入振动、电流、声学等高频传感器信号，提高对随机故障和早期弱故障的识别能力。此外，还可以把成本矩阵从固定参数扩展为动态参数：不同设备、不同生产阶段、不同备件库存状态下，误报和漏报成本并不相同。若能把模型预测、维修排班、备件库存和产线调度联合起来，预测性维护就不只是一个分类模型，而会成为更完整的工业决策系统。

参考文献

- [1] DUA D, GRAFF C. UCI Machine Learning Repository: AI4I 2020 Predictive Maintenance Dataset [Z]. <https://archive.ics.uci.edu/dataset/601/ai4i+2020+predictive+maintenance+dataset>. 2020.
- [2] CHEN T, GUESTRIN C. XGBoost: A Scalable Tree Boosting System[C]. in: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2016: 785-794.
- [3] KE G, MENG Q, FINLEY T, WANG T, CHEN W, MA W, et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree[C]. in: Advances in Neural Information Processing Systems. 2017.
- [4] WOLPERT D H. Stacked Generalization[J]. Neural Networks, 1992, 5(2): 241-259.
- [5] MATTHEWS B W. Comparison of the Predicted and Observed Secondary Structure of T4 Phage Lysozyme[J]. Biochimica et Biophysica Acta, 1975, 405(2): 442-451.
- [6] LUNDBERG S M, LEE S I. A Unified Approach to Interpreting Model Predictions[C]. in: Advances in Neural Information Processing Systems. 2017.